(19)国家知识产权局

(12)发明专利申请

(10)申请公布号 CN 120747212 A
(43)申请公布日 2025.10.03

(21)申请号 202510720439.X

(22)申请日 2025.05.30

(71)申请人 上海师范大学
地址 200234 上海市徐汇区桂林路100号

(72)发明人 安康 王岳 赵雯锦 管融
房家辉 张会 宋亚庆

(74)专利代理机构 上海唯智赢专利代理事务所(普通合伙) 31293
专利代理师 王圣

(51)Int.Cl.
G06T 7/73(2017.01)
G06N 3/0464(2023.01)

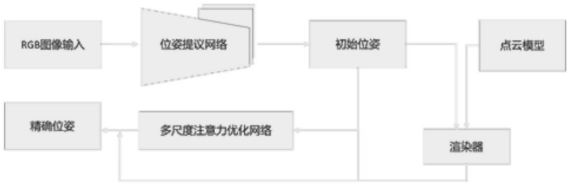
权利要求书2页 说明书5页 附图1页

(54)发明名称

一种基于位姿优化网络的6-DoF目标位姿估计方法

(57)摘要

本发明涉及一种基于位姿优化网络的6-DoF目标位姿估计方法,属于目标位姿估计技术领域,改进位姿优化网络由位姿提议网络和结合了一个渲染器和一个多尺度注意力优化网络的位姿优化网络组成,并进行如下步骤:步骤1:将目标的RGB图像输入位姿提议网络,向位姿优化网络输出目标的初始位姿估计;步骤2:初始位姿与点云模型生成的参考视角图片在渲染器中融合后生成多模态信息;步骤3:多模态信息与迭代后的初始位姿一同输入多尺度注意力优化网络进行细化,最终得到精确位姿。本发明通过位姿提议网络对目标对特征区域进行分割,通过位姿优化网络,结合位姿平移误差和旋转误差的角度有效地修正了位姿估计中的误差。



CN 120747212 A

1.一种基于位姿优化网络的6-DoF目标位姿估计方法,其特征在于:改进位姿优化网络由位姿提议网络和结合了一个渲染器和一个多尺度注意力优化网络的位姿优化网络组成,并进行如下步骤:

步骤1:将目标的RGB图像输入位姿提议网络,向位姿优化网络输出目标的初始位姿估计;

步骤2:初始位姿与点云模型生成的参考视角图片在渲染器中融合后生成多模态信息;

步骤3:多模态信息与迭代后的初始位姿一同输入多尺度注意力优化网络进行细化,最终得到精确位姿。

2.如权利要求1所述的6-DoF目标位姿估计方法,其特征在于:所述的位姿提议网络包括目标检测器和视角选择器,通过计算目标相似度得分,选择得分最高的区域进行分割,结合目标检测器估计的平移信息和视角选择器估计的旋转信息,获得一个初步的粗略物体位姿。

3.如权利要求1所述的6-DoF目标位姿估计方法,其特征在于:所述的步骤2中多模态信息的生成包括如下步骤:

步骤21:将初始位姿估计和参考视角图片进行裁剪后输入稠密对应点模块建立像素级特征匹配关系;

步骤22:选择与当前视角最接近的6张参考图像,将它们的特征进行投影并拼接,输入到三维卷积神经网络;

步骤23:选择与当前视图相似度最高的参考图像,建立稠密对应关系回归旋转残差,并进行迭代,得到迭代后的初始位姿。

4.如权利要求3所述的6-DoF目标位姿估计方法,其特征在于:所述的步骤21中稠密对应点模块通过二维特征编码器在两个视图之间匹配特征点,在利用多尺度特征来提高局部细节和全局信息的捕获能力,最后通过基于相似度的度量计算相似度得分,得到相似度最高的参考图像。

5.如权利要求1所述的6-DoF目标位姿估计方法,其特征在于:所述的多尺度注意力优化网络对位姿的细化包括如下步骤:

步骤31:引入混合空洞卷积,在网络第一层采用空洞率为2的卷积,以扩展输入区域;在第二层使用空洞率为4的卷积,以进一步扩大感受野;随后通过一个1×1的标准卷积核对特征进行精细化处理,形成细粒度的局部感受野,同时保留边缘信息;

步骤32:应用实例归一化处理输入数据,以确保在不同特征层之间的一致性,将来自不同特征层的输出通过特征融合操作整合,构建出多尺度的特征表示如下:$F_i = Conv(F_i\text{-}1) + Norm(F_i\text{-}1)$,其中$F_i$表示第$i_{th}$层的输出特征图;

步骤33:计算物体的旋转四元数、平移向量和尺度参数,以表示物体的完整位姿信息,并对旋转四元数进行归一化,旋转、平移和尺度的预测值表示如下:$r = \frac{FC1(x)}{||FC1(x)||}$,$t = ReLU(FC2(x))$,$s = sigmoid(FC3(x))$,其中r、t和s分别表示预测的旋转、平移和尺度值,x为物体特征;

步骤34:在相似度矩阵中寻找最高得分,检索两视图中的对应图像,选择置信度分数超过阈值的匹配对,并将其计入总匹配数n:

表示如下:$Criteria = \frac{1}{n}\sum_{i=1}^{N} \alpha_i \cdot \beta\left(b_i \geq \sigma\right)$,其中$b_i$表示第$i_{th}$个匹配点的置信度分数,β为指示函数,当其条件为真时返回1,否则返回0,α为每个匹配点的置信度的加权系数;

步骤35:选择置信度分数最高的作为最佳匹配对,得到物体的精确位姿估计。

一种基于位姿优化网络的6-DoF目标位姿估计方法

技术领域

[0001] 本发明属于位姿估计技术领域,具体涉及一种基于位姿优化网络的6-DoF目标位姿估计方法。

背景技术

[0002] 物体位姿估计的目的是确定物体在三维空间中的位置和位姿,是计算机视觉领域中的一个重要任务,通过位姿估计,计算机可以理解和感知物体的位置和方向,从而实现如目标跟踪、物体识别和机器人导航等高级的视觉任务,然而静态场景下的物体位姿估计已无法满足大多数应用需求,因此如何在动态、非结构化场景中实现高精度且高效的物体位姿估计是非常具有研究价值的课题。

[0003] 目前在动态、非结构化场景下进行大多依赖3D模型,需要进行封闭类别检测,并且有着对环境噪声敏感,以及需要密集标注视图等缺陷,因而在实际应用中受到限制。此外,基于模板的方法需要大量视图进行检索,且其位姿细化过程对旋转误差的敏感性不足,不能满足各种使用场景越来越高的要求。

发明内容

[0004] 本发明的目的是针对现有技术中存在的问题,提供一种基于位姿优化网络的6-DoF目标位姿估计方法,能有效地修正位姿估计中的位姿平移误差和旋转误差。

[0005] 技术方案如下:

[0006] 一种基于位姿优化网络的6-DoF目标位姿估计方法,改进位姿优化网络由位姿提议网络和结合了一个渲染器和一个多尺度注意力优化网络的位姿优化网络组成,并进行如下步骤:

[0007] 步骤1:将目标的RGB图像输入位姿提议网络,向位姿优化网络输出目标的初始位姿估计;

[0008] 步骤2:初始位姿与点云模型生成的参考视角图片在渲染器中融合后生成多模态信息;

[0009] 步骤3:多模态信息与迭代后的初始位姿一同输入多尺度注意力优化网络进行细化,最终得到精确位姿。

[0010] 进一步的,位姿提议网络包括目标检测器和视角选择器,通过计算目标相似度得分,选择得分最高的区域进行分割,结合目标检测器估计的平移信息和视角选择器估计的旋转信息,获得一个初步的粗略物体位姿。

[0011] 进一步的,步骤2中多模态信息的生成包括如下步骤:

[0012] 步骤21:将初始位姿估计和参考视角图片进行裁剪后输入稠密对应点模块建立像素级特征匹配关系;

[0013] 步骤22:选择与当前视角最接近的6张参考图像,将它们的特征进行投影并拼接,输入到三维卷积神经网络;

[0014] 步骤23:选择与当前视图相似度最高的参考图像,建立稠密对应关系回归旋转残差,并进行迭代,得到迭代后的初始位姿。

[0015] 更进一步的,步骤21中稠密对应点模块通过二维特征编码器在两个视图之间匹配特征点,在利用多尺度特征来提高局部细节和全局信息的捕获能力,最后通过基于相似度的度量计算相似度得分,得到相似度最高的参考图像。

[0016] 进一步的,多尺度注意力优化网络对位姿的细化包括如下步骤:

[0017] 步骤31:引入混合空洞卷积,在网络第一层采用空洞率为2的卷积,以扩展输入区域;在第二层使用空洞率为4的卷积,以进一步扩大感受野;随后通过一个1×1的标准卷积核对特征进行精细化处理,形成细粒度的局部感受野,同时保留边缘信息;

[0018] 步骤32:应用实例归一化处理输入数据,以确保在不同特征层之间的一致性,将来自不同特征层的输出通过特征融合操作整合,构建出多尺度的特征表示如下:$F_i=Conv(F_i\text{-}1)+Norm(F_i\text{-}1)$,其中$F_i$表示第$i_{th}$层的输出特征图;

[0019] 步骤33:计算物体的旋转四元数、平移向量和尺度参数,以表示物体的完整位姿信息,并对旋转四元数进行归一化,旋转、平移和尺度的预测值表示如下:$r=\frac{FC1(x)}{||FC1(x)||}$,t=ReLU(FC2(x)),s=sigmoid(FC3(x)),其中r、t和s分别表示预测的旋转、平移和尺度值,x为物体特征;

[0020] 步骤34:在相似度矩阵中寻找最高得分,检索两视图中的对应图像,选择置信度分数超过阈值的匹配对,并将其计入总匹配数n:表示如下:

$Criteria=\frac{1}{n}\sum_{i=1}^{N}\alpha_i\cdot\beta\left(b_i\geq\sigma\right)$,其中$b_i$表示第$i_{th}$个匹配点的置信度分数,β为指示函数,当其条件为真时返回1,否则返回0,α为每个匹配点的置信度的加权系数;

[0021] 步骤35:选择置信度分数最高的作为最佳匹配对,得到物体的精确位姿估计。

[0022] 有益效果:

[0023] 1)本发明通过位姿提议网络对目标对特征区域进行分割。

[0024] 2)通过位姿优化网络,结合位姿平移误差和旋转误差的角度有效地修正了位姿估计中的误差。

附图说明

[0025] 图1为本发明6-DoF目标位姿估计方法的流程图;

[0026] 图2为多模态信息的生成的流程图;

具体实施方式

[0027] 为了使本发明的目的、技术方案和优点更加清楚明白,以下结合附图及实施例,对本发明进行进一步详细说明。应当理解,此处所描述的具体实施例仅仅用以解释本发明,并不用于限定本发明,术语“上”、“下”、“前”、“后”、“左”、“右”、“底”、“内”、“外”等指示的方位或位置关系为基于附图所示的方位或位置关系,仅是为了便于描述本发明,而不是指示或暗示所指的装置或元件必须具有特定的方位、以特定的方位构造和操作,因此不能理解为对本发明的限制。

[0028] 如图1所示一种基于位姿优化网络的6-DoF目标位姿估计方法,改进位姿优化网络由位姿提议网络和结合了一个渲染器和一个多尺度注意力优化网络的位姿优化网络组成,并进行如下步骤:

[0029] 步骤1:将目标的RGB图像输入位姿提议网络,向位姿优化网络输出目标的初始位姿估计;

[0030] 步骤2:初始位姿与点云模型生成的参考视角图片在渲染器中融合后生成多模态信息;

[0031] 步骤3:多模态信息与迭代后的初始位姿一同输入多尺度注意力优化网络进行细化,最终得到精确位姿。

[0032] 位姿提议网络包括目标检测器和视角选择器,通过计算目标相似度得分,选择得分最高的区域进行分割,结合目标检测器估计的平移信息和视角选择器估计的旋转信息,获得一个初步的粗略物体位姿。

[0033] 如图2所示,步骤2中多模态信息的生成包括如下步骤:

[0034] 步骤21:将初始位姿估计和参考视角图片进行裁剪后输入稠密对应点模块建立像素级特征匹配关系,稠密对应点模块通过二维特征编码器在两个视图之间匹配特征点,在利用多尺度特征来提高局部细节和全局信息的捕获能力,最后通过基于相似度的度量计算相似度得分,得到相似度最高的参考图像;

[0035] 步骤22:选择与当前视角最接近的6张参考图像,将它们的特征进行投影并拼接,输入到三维卷积神经网络;

[0036] 步骤23:选择与当前视图相似度最高的参考图像,建立稠密对应关系回归旋转残差,并进行迭代,得到迭代后的初始位姿。

[0037] 多尺度注意力优化网络对位姿的细化包括如下步骤:

[0038] 步骤31:引入混合空洞卷积,在网络第一层采用空洞率为2的卷积,以扩展输入区域;在第二层使用空洞率为4的卷积,以进一步扩大感受野;随后通过一个1×1的标准卷积核对特征进行精细化处理,形成细粒度的局部感受野,同时保留边缘信息;

[0039] 步骤32:应用实例归一化处理输入数据,以确保在不同特征层之间的一致性,将来自不同特征层的输出通过特征融合操作整合,构建出多尺度的特征表示如下:F_i=Conv(F_i-1)+Norm(F_i-1),其中F_i表示第i_{th}层的输出特征图;

[0040] 步骤33:计算物体的旋转四元数、平移向量和尺度参数,以表示物体的完整位姿信息,并对旋转四元数进行归一化,旋转、平移和尺度的预测值表示如下:$r = \frac{FC1(x)}{||FC1(x)||}$,t=ReLU(FC2(x)),s=sigmoid(FC3(x)),其中r、t和s分别表示预测的旋转、平移和尺度值,x为物体特征;

[0041] 步骤34:在相似度矩阵中寻找最高得分,检索两视图中的对应图像,选择置信度分数超过阈值的匹配对,并将其计入总匹配数n:表示如下:

$Criteria = \frac{1}{n}\sum_{i=1}^{N} \alpha_i \cdot \beta\,(b_i \geq \sigma)$,其中$b_i$表示第$i_{th}$个匹配点的置信度分数,β为指示函数,当其条件为真时返回1,否则返回0,α为每个匹配点的置信度的加权系数;

[0042] 步骤35:选择置信度分数最高的作为最佳匹配对,得到物体的精确位姿估计。

[0043] 实施例1:使用LINEMOD、GenMOP、ShapeNet和Google Scanning Objects数据集用基于位姿优化网络的6-DoF目标位姿估计方法进行训练,并在LINEMOD和GenMOP上进行评估,其中LINEMOD数据集包含13个弱纹理物体的1,578张图像,而GenMOP包含10个物体(如“剪刀”和“椅子”),每个物体在两段不同条件下的视频序列中采集,每个序列包含200帧图像,得到结果如下表所示:

[0044] 表1.在LINEMOD-Occ数据集上基于ADD-0.1d指标的评估结果,对比类无关(category-agnostic)基线方法。

[0045]

Ref. Num	Ref. Num	eggbox	duck	glue	ape	Avg.
Gen6D[32]	20	0.02	0.07	0.03	0.12	0.06
SA6D[38]	20	0.08	0.09	0.04	0.10	0.07
LF[39]	20	0.01	0.00	0.18	0.45	0.16
Ours	20	0.11	0.18	0.24	0.32	0.21

[0046] 表2.在LINEMOD数据集上的测试。

[0047]

Metrics	Method	Cat	Duck	Lamp	Driller	Avg.
Add	Brachmann [37]	42.70	30.20	67.00	61.90	50.45
	OnePose[25]	45.81	33.99	85.32	71.26	59.09

[0048]

	Gen6D[32]	60.68	41.97	89.83	67.39	64.96
	Ours	64.57	43.60	91.12	79.09	69.59
Metrics	Method	Cat	Duck	Lamp	Driller	Avg
Proj-2D	Brachmann [37]	42.70	30.20	67.00	61.90	50.45
	OnePose[25]	75.64	71.17	87.52	75.02	77.33
	Gen6D[32]	95.81	80.85	91.17	73.34	85.29
	Ours	95.19	88.03	93.04	71.89	87.03

[0049] 表3.在LINEMOD数据集上的测试,测量了中位误差以及在30°和15°下的平均精度。

[0050]

Dataset	Method	All Categeries			Per Category(Med.Err↓)			
		Med. Err(↓)	Acc30(↑)	Acc15(↑)	Egg box	Can	Iron	Camera
LINEMOD	Gen6D	44.85	0.36	0.09	31.78	30.40	30.09	35.97
	LoFTR	33.03	0.56	0.32	16.88	17.58	17.90	22.55
	Ours	24.53	0.67	0.39	12.14	17.92	15.23	19.03

[0051] 以上所述仅为本发明的较佳实施例而已,并不用于限制本发明,凡在本发明的原则和精神之内所作的任何修改、等同替换和改进等,均应包含在本发明的保护范围之内。

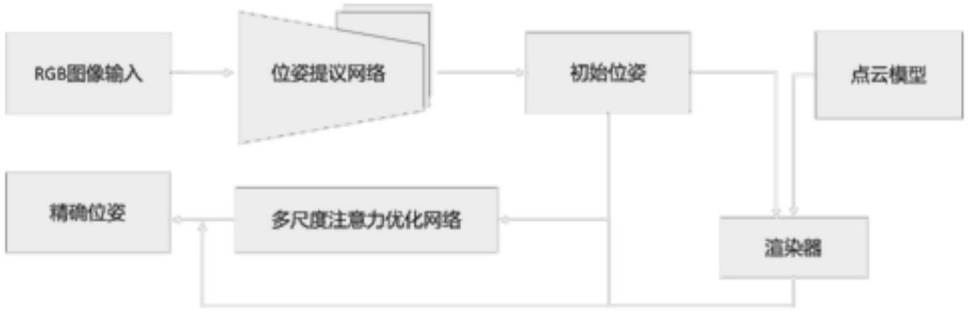

RGB图像输入
位姿提议网络
初始位姿
点云模型
精确位姿
多尺度注意力优化网络
渲染器

图1

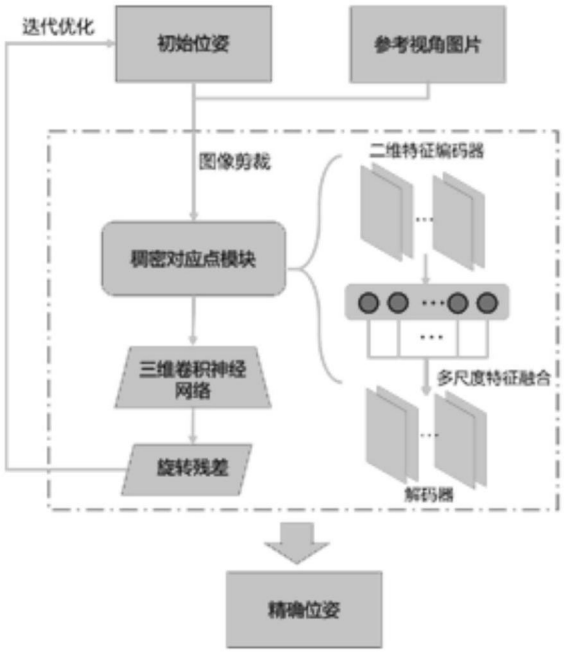

迭代优化
初始位姿
参考视角图片
图像剪裁
二维特征编码器
稠密对应点模块
三维卷积神经网络
旋转残差
多尺度特征融合
解码器
精确位姿

图2